

## 1 Méthode de Monte Carlo

Soient  $(U_1, \dots, U_d)$  un vecteur de  $d$  variables aléatoires indépendantes toutes de loi uniforme sur  $[0, 1]$ , et  $f$  est une fonction de carré intégrable sur  $[0, 1]^d$ . On considère la variable aléatoire  $X = f(U_1, \dots, U_d)$ . D'après la loi forte des grands nombres, si  $X_n$  est une suite de variables aléatoires indépendantes toutes de même loi que  $X$ ,  $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n f(X_i) = E(f(X)) = \int_{[0,1]^d} f(u_1, \dots, u_d) du_1 \dots du_d$ . La méthode de Monte Carlo consiste à utiliser ceci pour calculer une approximation de  $\int_{[0,1]^d} f(u_1, \dots, u_d) du_1 \dots du_d$ . Le théorème central limite permet de plus d'avoir une idée de l'ordre de grandeur de l'erreur. La convergence est en  $\frac{\sigma}{\sqrt{n}}$ , indépendamment de  $d$ . L'intérêt par rapport à d'autres méthodes déterministes, qui approchent l'intégrale par exemple par des sommes de Riemann, se fait donc surtout sentir pour des intégrales multiples. En effet l'erreur avec ce genre de méthodes est en général en  $(\text{Pas de la subdivision})^{-1}$ .

On va se servir de la méthode de Monte-Carlo pour calculer  $\pi$ .

1. On va d'abord utiliser  $\pi = \int_0^1 4\sqrt{1-x^2} dx$ . Générer un 500 échantillon  $[U_1, \dots, U_{500}]$  de loi uniforme sur  $[0, 1]$ . Obtenir l'échantillon  $[X_1, \dots, X_{500}]$  où  $X_i = 4\sqrt{1-U_i^2}$ . Donner une estimation de  $\pi = E[X]$  et de l'écart-type de  $X$ , et donner un intervalle de confiance pour  $\pi$  au risque 0.05.
2. On va déterminer un intervalle de confiance pour  $\pi$  en utilisant  $\pi = 4 \int_{[0,1]^2} 1_{x^2+y^2 \leq 1} dx dy$ . Quelle est la loi de  $X_i$  ? Donner une estimation de  $\pi$  et de l'écart-type de  $X_i$ , et donner un intervalle de confiance pour  $\pi$  au risque 0.05.
3. Déterminer un intervalle de confiance pour  $\pi$  en utilisant  $\pi = 6 \int_{[0,1]^3} 1_{x^2+y^2+z^2 \leq 1} dx dy dz$ .

## 2 Régression linéaire

On considère le modèle de régression linéaire simple  $Y_i = a + bX_i + \epsilon_i, i = 1, \dots, n$  où  $a$  et  $b$  sont des paramètres inconnus, et où les  $\epsilon_i$  sont des variables aléatoires indépendantes de loi  $N(0, \sigma^2)$ , où  $\sigma$  est un troisième paramètre également inconnu.

1. On estime  $a$  et  $b$  par la méthode des moindres carrés, qui consiste à prendre les  $a$  et  $b$  qui minimisent  $\Delta = \sum_{i=1}^n (Y_i - (a + bX_i))^2$ . En notant

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, \overline{XY} = \frac{1}{n} \sum_{i=1}^n X_i Y_i, \sigma_X^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

on obtient  $\hat{b} = \frac{\overline{XY} - \bar{X}\bar{Y}}{\sigma_X^2}$  et  $\hat{a} = \bar{Y} - \hat{b}\bar{X}$ . Pour estimer  $\sigma$  on utilise  $\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{a} - \hat{b}X_i)^2$ .

Prendre  $n = 50$ ,  $X_i = \frac{i}{n}$ ,  $a = 1$ ,  $b = 2$ ,  $\sigma = 0.5$ ; générer un 50 échantillon  $(\epsilon_1, \dots, \epsilon_{50})$  et en déduire les  $Y_i$ . Quelles sont les valeurs estimées  $\hat{a}$ ,  $\hat{b}$ ,  $\hat{\sigma}$  ? Représenter les points de coordonnées  $(X_i, Y_i)$  sur un dessin, ainsi que la droite de régression linéaire  $y = \hat{a} + \hat{b}x$  et la "vraie" droite  $y = a + bx$ .

2. L'un des intérêts des estimateurs  $\hat{a}$ ,  $\hat{b}$  et  $\hat{\sigma}^2$  est qu'ils sont sans biais (vous pouvez le vérifier).

D'autre part, on peut montrer que  $\hat{a}$  suit une loi normale d'espérance  $a$  et de variance  $\frac{\sigma^2}{n} (1 + \frac{\bar{x}^2}{\sigma_X^2})$ , que  $\hat{b}$  suit une loi normale d'espérance  $b$  et de variance  $\frac{\sigma^2}{\sigma_X^2 n}$ , et que  $(n-2) \frac{\hat{\sigma}^2}{\sigma^2}$  suit une loi du  $\chi_2$  à  $n-2$  degrés de liberté. De plus,  $(\hat{a}, \hat{b})$  est indépendant de  $\hat{\sigma}$ .

En déduire un intervalle de confiance pour  $a$  et  $b$  au risque 0.05. (Faire intervenir une loi de Student...) Tracer sur le même dessin que précédemment les droites limites  $y = a_{min} + b_{min}x$  et  $y = a_{max} + b_{max}x$ .

Donner également un intervalle de confiance pour  $\sigma$ .

3. Si on note  $C = \overline{XY} - \bar{X}\bar{Y}$  et  $\sigma_Y^2 = \frac{1}{n} \sum_{i=1}^n Y_i^2 - \bar{Y}^2$ , la droite de régression orthogonale, (la droite qui passe par  $(\bar{X}, \bar{Y})$  et qui minimise la somme des carrés des distances à la droite) a pour équation  $y = \bar{Y} + (x - \bar{X}) \frac{\sigma_Y^2 - \sigma_X^2 + \sqrt{(\sigma_X^2 - \sigma_Y^2)^2 + 4C^2}}{2C}$ . La tracer sur le même graphe que la droite de régression linéaire précédente.