

## TP 7. Tests du $\chi^2$

### 1 Mise en route...

Faire l'application numérique du dernier exercice du TD sur les tests et donner le résultat du test (réponse : on accepte  $H_0$ ...les garçons ne sont pas significativement meilleurs, et les filles non plus, bien que les deux moyennes empiriques diffèrent de près de 1.5...

### 2 Test d'ajustement du $\chi^2$

Soit  $(X_1, \dots, X_n)$  un  $n$ -échantillon de loi inconnue  $\mu$ . On veut tester  $H_0$ : « $\mu = \nu$ », contre  $H_1$ : « $\mu \neq \nu$ », où  $\nu$  est une loi de probabilité fixée et connue. On considère une partition en  $k$  classes  $(I_1, \dots, I_k)$  du support de  $\nu$ . On note  $\nu_1, \dots, \nu_k$  les poids associés (c'est-à-dire  $\nu_i = P(Y \in I_i)$  si  $Y$  suit la loi  $\nu$ ), que l'on supposera toujours strictement positifs. Lorsque  $\nu$  est une loi discrète finie, les classes sont des singletons typiquement, et  $\nu_i = P(Y = y_i)$ . Pour  $i = 1, \dots, k$ , soit  $n_i$  l'effectif associé à la classe  $I_i$ , c'est-à-dire le nombre d'observations de la classe  $I_i$  dans le  $n$ -échantillon (on a donc  $n = \sum_{i=1}^k n_i$ ). La statistique de test d'ajustement est

$$D_n = \sum_{i=1}^k \frac{(d_i - n_i)^2}{d_i}$$

avec  $d_i = n\nu_i$ . La loi forte des grands nombres et le théorème central limite ont pour conséquence le théorème suivant.

**Théorème 1 (Khi-deux d'ajustement)** *Lorsque  $n$  tend vers  $+\infty$ ,  $D_n$  converge en loi vers  $\chi^2(k-1)$  sous  $H_0$ , et presque sûrement vers  $+\infty$  sous  $H_1$ .*

En pratique, pour  $n$  assez grand ( $\inf_i d_i > 5$ ), on approche sous  $H_0$  la loi de  $D_n$  par  $\chi^2(k-1)$ . On en déduit alors un test qui consiste à rejeter  $H_0$  si  $D_n > \chi_\alpha^2(k-1)$ , où  $\chi_\alpha^2(k-1)$  est le quantile  $1 - \alpha$  de la loi  $\chi^2(k-1)$  (c'est-à-dire  $P(Z \leq \chi_\alpha^2(k-1)) = 1 - \alpha$  si  $Z$  suit une loi du  $\chi^2$  à  $k-1$  degrés de liberté. Ce test est asymptotiquement de niveau  $\alpha$  et de puissance 1 (i.e. convergent). En effet, on a  $P(D_n > \chi_\alpha^2(k-1)) \rightarrow_{+\infty} \alpha$  sous  $H_0$ , tandis que sous  $H_1$ ,  $P(D_n > \chi_\alpha^2(k-1)) \rightarrow 1$ . Lorsque la loi  $\nu$  n'est pas entièrement connue, on perd un degré de liberté pour chaque paramètre estimé.

1. Écrire une procédure qui prend en entrée le nombre de classes  $k$ , le tableau des observations  $n_i$ , le tableau de la loi définissant  $H_0$   $\nu_i$ , le niveau  $\alpha$  et fournit le résultat du test du  $\chi^2$ .
2. Application : test d'un générateur pseudo-aléatoire.  
Un ordinateur possède un générateur pseudo-aléatoire de nombres choisis

au hasard dans l'ensemble des dix premiers entiers. Les mille premiers résultats sont répartis dans le tableau suivant.

| Chiffres     | 0   | 1  | 2   | 3   | 4  | 5   | 6  | 7   | 8  | 9  |
|--------------|-----|----|-----|-----|----|-----|----|-----|----|----|
| Observations | 120 | 87 | 115 | 103 | 91 | 109 | 92 | 112 | 94 | 77 |

Peut-on accepter l'hypothèse d'équiprobabilité pour chacun des chiffres ?

- Faites de même en remplaçant la table précédente par une table générée par maple (utiliser *discreteuniform*[0..9]).  
Pour transformer l'échantillon *Ech* fourni par maple en tableau avec le nombre d'observations, faire les deux opérations suivantes :  
 $Ech2 := transform[tally](Ech);$  (Groupe les données ensembles)  
 $Ech3 := transform[frequency](Ech2);$  (Ne garde que les fréquences)
- On a classé 10000 familles ayant 4 enfants en fonction du nombre de garçons, et on a obtenu :

| Garçons  | 0   | 1    | 2    | 3    | 4   |
|----------|-----|------|------|------|-----|
| Effectif | 572 | 2329 | 3758 | 2632 | 709 |

Si on suppose que les naissances "Garçons/Filles" sont équiprobables et indépendantes, quelle est la loi du nombre de garçons ? Tester cette hypothèse. Jusqu'à quelle valeur  $\alpha$  garde-t-on  $H_0$  ? Il semble donc raisonnable de rejeter  $H_0$ . On relâche donc la condition de "équiprobable", et on estime la probabilité  $\hat{p}$  d'avoir un garçon par la moyenne arithmétique du nombre de garçons divisée par 4. On teste alors l'indépendance en prenant pour  $H_0$  "le nombre de garçons suit la loi  $B(4, \hat{p})$ ". On peut montrer qu'alors  $D_n$  converge en loi vers  $\chi_2(4 - 2)$ . Effectuer ce nouveau test. Quelle est votre conclusion ?

- Écrire une procédure qui prend en paramètre  $\alpha$  et  $\epsilon$ , génère 100 100-échantillons de loi sur  $\{1, 2, 3, 4\}$   $\{0.25, 0.25, 0.25 - \epsilon, 0.25 + \epsilon\}$ , effectue pour chacun d'eux le test du Khi-deux d'ajustement au risque  $\alpha$  avec  $H_0 : \mu = \{0.25, 0.25, 0.25, 0.25\}$ , compte le nombre de fois où la réponse est fausse et en déduit une estimation de l'erreur de deuxième espèce dans ce cas. (Pour générer un échantillon avec une loi donnée  $P(X = i) = p_i$ , utiliser *random[empirical*[ $p_1, p_2, p_3, p_4$ ]];

Lancer la procédure avec  $\alpha = 0.05$ , et  $\epsilon = 0.01, 0.05$  et  $0.1$ . Quelle est la loi du nombre de réponses fausses ? Quelle est approximativement la loi de cet estimateur pour l'erreur de deuxième espèce ? Quelle est ici approximativement son écart-type ?

### 3 Test d'indépendance

Soient  $(X_1, \dots, X_n)$  et  $(Y_1, \dots, Y_n)$  deux  $n$ -échantillons dont la loi du couple  $\mu_{(X,Y)}$  est inconnue. On note  $\mu_X$  et  $\mu_Y$  les lois marginales associées. On veut tester  $H_0$ : « $\mu_{(X,Y)} = \mu_X \otimes \mu_Y$ », contre  $H_1$ : « $\mu_{(X,Y)} \neq \mu_X \otimes \mu_Y$ ». On suppose que les supports de  $\mu_X$  et  $\mu_Y$  sont partitionnés en  $k$  classes  $(I_1, \dots, I_k)$  et  $l$  classes  $(J_1, \dots, J_l)$  respectivement. Pour  $i = 1, \dots, k$  et  $j = 1, \dots, l$ , soit  $n_{i,j}$  l'effectif associé aux classes  $I_i$  et  $J_j$ . On pose  $n_{i*} = \sum_{j=1}^l n_{i,j}$  et  $n_{*j} = \sum_{i=1}^k n_{i,j}$  les effectifs «marginaux». Sous l'hypothèse  $H_0$ , il est naturel d'estimer  $\mu_{(X,Y)}$  par  $\hat{\mu} = \{\hat{\mu}_{i,j} := \frac{n_{i*}}{n} \frac{n_{*j}}{n}, 1 \leq i \leq k, 1 \leq j \leq l\}$ . La statistique de test d'indépendance est

$$D_n = \sum_{i=1}^k \sum_{j=1}^l \frac{(d_{i,j} - n_{i,j})^2}{d_{i,j}}$$

où  $d_{i,j} = n\hat{\mu}_{i,j} = n_{i*}n_{*j}/n$ .

**Théorème 2 (Khi-deux d'indépendance)** *Lorsque  $n$  tend vers  $+\infty$ , la statistique de test  $D_n$  converge en loi vers un  $\chi^2((k-1)(l-1))$  sous  $H_0$  et converge presque sûrement vers  $+\infty$  sous  $H_1$ .*

En pratique, pour  $n$  grand, on peut sous  $H_0$  approcher la loi de  $D_n$  par  $\chi^2((k-1)(l-1))$ . Ici encore, le test consistant à rejeter  $H_0$  dès que  $D_n > \chi_\alpha^2((k-1)(l-1))$  est asymptotiquement de niveau  $\alpha$  et de puissance 1.

1. Écrire une procédure qui prend en entrée  $k, l$ , le tableau des effectifs  $n_{ij}$  ainsi que le niveau du test et donne le résultat du test.

Pour rentrer un tableau à deux entrées, le plus simple est de faire, par exemple

$A := [[1, 3, 4], [2, 5, 6]]$ ;

On a ainsi  $A[1][1] = 2$ , et  $A[2][3] = 6$ .

2. Afin de savoir si les *Mathématiciens sont Philosophes*, on a relevé, sur 100 bacheliers, les notes obtenues en Mathématiques  $X$  et en Philosophie  $Y$ .

| $X \setminus Y$ | $[0,4[$ | $[4,8[$ | $[8,12[$ | $[12,16[$ | $[16,20]$ |
|-----------------|---------|---------|----------|-----------|-----------|
| $[0,4[$         | 3       | 4       | 2        | 0         | 0         |
| $[4,8[$         | 6       | 10      | 8        | 2         | 0         |
| $[8,12[$        | 1       | 8       | 20       | 12        | 3         |
| $[12,16[$       | 0       | 0       | 8        | 7         | 3         |
| $[16,20]$       | 0       | 0       | 1        | 0         | 2         |

Tester l'hypothèse d'indépendance entre les notes obtenues en Mathématiques et en Philosophie.

3. Visions de gauche et de droite

Les scores de vision aux deux yeux de 7477 femmes, âgées de 30 à 40 ans, ont été classés en quatre groupes notés de 1 à 4 par ordre décroissant.

| $D \setminus G$ | 1    | 2    | 3    | 4   |
|-----------------|------|------|------|-----|
| 1               | 1520 | 266  | 124  | 66  |
| 2               | 234  | 1512 | 432  | 78  |
| 3               | 117  | 362  | 1772 | 205 |
| 4               | 36   | 82   | 179  | 492 |

Tester l'hypothèse d'indépendance entre les deux yeux.