

TP Statistique n°2

Simulation de lois

Rappel : taper `krdc vnc://nom_du_serveur` dans un terminal.

Les sujets et les corrigés des TP sont mis le lendemain des séances sur ma page :

<http://www.math.u-bordeaux1.fr/~duprey/stat.html>

1. REPRÉSENTATIONS GRAPHIQUES D'ÉCHANTILLONS STATISTIQUES

1.1. Rappel : Histogramme. On utilise la commande `histo`. Si X est un vecteur, `histo` trace un histogramme non normalisé. Pour le normaliser, il faut donner 4 paramètres, par exemple `histo(X,10,0,1)`. Le deuxième paramètre est le nombre de classes (ou de colonnes, en anglais "bins" de l'histogramme), le troisième paramètre vaut 0 ou 1 (en général 0 pour une loi continue, 1 pour une discrète mais ce n'est pas crucial), et le quatrième vaut 1 pour indiquer que l'histogramme est normalisé.

1. Générer un échantillon de 1000 réalisations d'une loi normale centrée réduite (utiliser `randn`). Obtenir son histogramme, et tracer sa densité sur le même graphe (soit avec `dnorm`, soit en utilisant la formule de la densité d'une loi normale centrée réduite). Comparer sa moyenne empirique et son espérance, ainsi que son écart-type empirique et théorique.

La bibliothèque `stixbox` (`help stixbox`) permet de générer un certain nombre de lois. Attention la loi géométrique est sur $\mathbb{N}$ au lieu de $\mathbb{N}^*$ et le deuxième paramètre de la loi normale est son écart-type, pas sa variance!

2. Générer un échantillon d'une loi binomiale et comparer l'espérance et la moyenne empirique, ainsi que l'écart-type et l'écart-type empirique. Obtenir son histogramme, et comparer avec les probabilités théoriques (utiliser `dbinom`).

Ici on est dans le cas d'une loi discrète : donc le mieux est de prendre comme nombre de classes dans l'histogramme le nombre de valeurs observées (a priori $\max(\text{échantillon}) - \min(\text{échantillon}) + 1$). Ici ce sera également mieux de prendre 1 en troisième paramètre de l'histogramme : essayer avec 0 pour comparer. Il vaut mieux ici dessiner les probabilités théoriques à l'aide de `stem` plutôt que `plot`. Enfin, attention, la loi de probabilités n'est vraiment définie que pour des entiers, donc de toute manière NE PAS utiliser `fplot`...

3. Faire de même avec une loi de Poisson (`rpoiss`) (la factorielle se note `factorial`).

1.2. Fonction de répartition. Il est souvent plus fiable de comparer des fonctions de répartition empirique et théorique, qu'un histogramme avec une densité. Plusieurs moyens sont possibles pour tracer une fonction de répartition empirique. Si X est un vecteur aléatoire de taille n , on peut par exemple effectuer les opérations suivantes :

`Y=sort(X);` Trie le vecteur X .

`stairs(Y,[1:n]/n)` Dessine la fonction de répartition empirique

4. Générer un échantillon de 1000 réalisations d'une loi normale et tracer sa fonction de répartition empirique. Obtenir sur le même graphe la fonction de répartition théorique (Utiliser `pnorm`)

5. Ecrire une fonction `plotrep` qui prend en entrée un vecteur et trace la fonction de répartition empirique correspondante.

2. GÉNÉRATION ALÉATOIRE

2.1. Transformations plus ou moins élémentaires de la loi uniforme.

6. Générer un échantillon X de 1000 réalisations d'une loi uniforme sur $[0, 1]$. Obtenir à partir de X un échantillon de 1000 réalisations d'une loi uniforme sur $[1, 2]$. Obtenir un échantillon de 1000 réalisations d'une loi uniforme sur $[0, 2]$, un échantillon de 1000 réalisations d'une loi uniforme sur $[-1, 1]$ (faire des histogrammes pour vérifier)

8. Ecrire une fonction **runif** qui prend en argument n, a et b et fournit un échantillon de n réalisations d'une loi uniforme sur $[a, b]$. Obtenir ainsi un échantillon de loi uniforme sur $[-3, 4]$.

9. Obtenir à partir d'un échantillon d'une loi uniforme sur $[0, 1]$ un échantillon de loi de Bernoulli de paramètre $\frac{1}{2}$ (penser aux opérations booléennes!). Calculer sa moyenne et comparer avec son espérance.

10. Ecrire une fonction **rbernou** qui prend en argument n, m, p et fournit une matrice $n \times m$ de réalisations d'une loi de Bernoulli de paramètre p .

11. Obtenir à partir d'un échantillon d'une loi uniforme sur $[0, 1]$ un échantillon de loi uniforme discrète sur $\{1, 2, \dots, 10\}$ (Indication : utiliser **ceil**) Obtenir son histogramme, calculer sa moyenne et comparer avec son espérance.

12. Ecrire une fonction **runifd** qui prend en argument n, N et fournit un échantillon de n réalisations d'une loi uniforme discrète sur $\{1, 2, \dots, N\}$ et l'utiliser pour simuler 1000 lancers de dé.

13. Question subsidiaire : écrire une fonction **discrete1** qui génère un n -échantillon d'une loi sur $\{1, 2, 3\}$ avec probabilités respectives $\frac{1}{2}, \frac{1}{3}, \frac{1}{6}$.

Question subsidiaire de la question subsidiaire : écrire une fonction **discrete2** qui prend en paramètre un entier n et un vecteur p et génère un n -échantillon d'une loi sur $\{1, 2, \dots, \text{length}(p)\}$ avec probabilités respectives $p(1), p(2), \dots, p(\text{length}(p))$.

2.2. Inversion de la fonction de répartition.

14. Soit X une variable aléatoire de loi uniforme sur $[0, 1]$ et λ un réel positif. Quelle est la loi de $-\lambda \ln(X)$?

Ecrire une fonction **rexp** qui prend en paramètre un entier n et un réel a et génère un n -échantillon d'une loi exponentielle de paramètre a (attention la fonction $\ln$ s'appelle **log**). L'utiliser pour générer un échantillon de loi exponentielle de paramètre 2, vérifier en traçant l'histogramme et la densité sur un même graphe, puis la fonction de répartition empirique et la fonction de répartition théorique. Comparer la moyenne empirique et l'espérance.

2.3. Utilisation des propriétés des lois. La somme de N variables aléatoires i.i.d. de loi de Bernoulli de paramètre p suit une loi binomiale de paramètres N, p .

15. Utiliser ce résultat pour écrire une fonction **rbino2** qui prend en paramètres n, N et p et génère un échantillon de n variables de loi binomiale de paramètres N, p (utiliser votre fonction **rbernou**, et penser à la fonction **sum**).

Utiliser **type** **rbinom** pour voir le code effectivement utilisé par **stirbox** pour générer une loi binomiale. Est-ce la même méthode ? Sinon, quels sont leurs intérêts respectifs

16. Question subsidiaire : Utiliser la définition de la loi géométrique comme instant de premier succès pour générer un échantillon de 1000 réalisations de loi géométrique de paramètre $\frac{1}{6}$ (penser à utiliser une boucle **while**). Comparer la moyenne et l'espérance, et tracer sur un même graphe l'histogramme et la loi de probabilité. **rgeom** utilise-t-il la même méthode ?

17. Si X suit une loi normale centrée réduite et si a et b sont deux réels, quelle est la loi de $aX + b$? Utiliser ce résultat pour générer (en utilisant **randn**) un échantillon de 1000 réalisations d'une loi normale d'espérance 10 et de variance 25. (Si vous avez le temps, comparer l'histogramme et la densité). **norm** utilise-t-il la même méthode ?

2.4. **Méthode par rejet.** Une méthode souvent utilisée pour générer une variable aléatoire de loi uniforme sur un ensemble E un peu compliqué est de générer une variable X de loi uniforme sur un ensemble $F \supset E$ puis de tester si X appartient à E : si oui, on la garde, et sinon on retire une variable X jusqu'à tomber dans E . La commande **find** va être très utile pour cela : si X est un vecteur, **find(X)** retourne les indices pour lesquels X est non nul; et donc (par exemple) **J=find(X<1)** retourne les indices pour lesquels X est inférieur à 1, et **X(J)** désigne le vecteur où on a gardé uniquement les composantes inférieures à 1.

18. Générer deux vecteurs X et Y contenant les abscisses et les ordonnées de 10000 points distribués de manière uniforme sur $[-1, 1] \times [-1, 1]$. Utiliser **find** pour déterminer l'ensemble des indices i pour lesquels le point de coordonnées $(X(i), Y(i))$ appartient au disque de centre 0 de rayon 1. Obtenir deux sous-vecteurs Xd, Yd ne contenant que les valeurs de X et de Y correspondant à ces indices. Tracer les points de coordonnées Xd et Yd .

Pour que les points ne soient pas reliés par des segments de droite il faut dire à matlab d'utiliser des symboles (par exemple mettre '**d**' en option de **plot**, qui va utiliser des losanges).

On peut sur la même figure tracer le cercle unité à l'aide de

```
t=[0:pi/30:2*pi]; plot(exp(i*t))
```

(à condition que i désigne toujours le nombre imaginaire); on peut également utiliser **polar** qui dessine une courbe en coordonnées polaires (faire **help polar**)

Quelle est la loi de la taille de Xd et Yd ?

Xd et Yd suivent-ils une loi uniforme ?

19. Générer maintenant deux vecteurs r et t de loi respectivement uniforme sur $[0, 1]$ et uniforme sur $[0, 2\pi]$ et tracer les points de coordonnées $(r \cos t, r \sin t)$. On n'obtient ainsi que des points dans le disque. La distribution vous semble-t-elle uniforme ?

20. Question subsidiaire. On considère une cardioïde de paramètre 1, d'équation en polaire $r = 1 + \cos \theta$. On admettra qu'elle est incluse dans $[-\frac{1}{4}, 2] \times [-3\frac{\sqrt{3}}{4}, 3\frac{\sqrt{3}}{4}]$. Générer un échantillon de points de loi uniforme sur l'intérieur de la cardioïde et les représenter ainsi que la cardioïde.

Il pourra être utile d'utiliser **cart2pol** qui permet de passer des coordonnées cartésiennes aux coordonnées polaires.